

HrFlow.ai

Recommandation d'Emploi Basée sur le Comportement avec
Apprentissage Machine en Ligne et Filtrage Collaboratif

Plan

1. Présentation des données et métriques
2. Baseline : Collaborative Filtering (CF)
3. Singular Value Decomposition (SVD) with CF
4. Méthode à base de graphes
5. CF avec job embeddings

Données

- 18k sessions candidats, dont 16k d'entraînement et 2k de test.
- 22k offres d'emploi uniques.
- Une matrice d'embedding utilisant le modèle multilingue e5 large.

Métriques

- Mean Reciprocal Rank (MRR) : Mesure la moyenne de la position de l'emploi correct parmi les 10 emplois prédits.
- Accuracy : Évalue la capacité du modèle à prédire si l'action suivante du candidat sera une candidature ou une consultation.
- Final score : Combinaison pondérée de MRR (70%) et de l'accuracy (30%).
- HitRate(k) : Mesure la fréquence à laquelle l'emploi correct est parmi les k premiers résultats (k = 10).

Baseline : Collaborative Filtering

Matrice d'interaction utilisateur-emploi :

- $R_{ui} = 1$ si l'utilisateur a consulté ou postulé à l'emploi i .
- $R_{ui} = 0$ si l'utilisateur n'a pas interagi avec l'emploi i .

$$R = \begin{bmatrix} R_{11} & R_{12} & \cdots & R_{1m} \\ R_{21} & R_{22} & \cdots & R_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ R_{n1} & R_{n2} & \cdots & R_{nm} \end{bmatrix}$$

Baseline : Collaborative Filtering

k	Theta	MRR	Accuracy	Final score
10	0.2	0.0204	0.5000	0.1643
10	0.3	0.0204	0.6078	0.1966
10	0.4	0.0204	0.6169	0.1993
10	0.5	0.0204	0.6069	0.1964

Meilleurs hyperparamètres : $k = 21$, $\theta = 0.3$.

MRR = 0.0218, Accuracy = 0.6249, Final score = 0.2027.

Baseline : Collaborative Filtering

Model	Final score
CF	0.194
Baseline	0.192

Collaborative Filtering avec SVD

- Reconstruction directe des scores : On prédit directement les interactions en utilisant la décomposition SVD.
- Hyperparamètre k : k devient le nombre de dimensions latentes retenues (nombre de valeurs singulières).

Collaborative Filtering avec SVD


k	Theta	Apply weight	View weight	Final score
20	0.3	1	1	0.2002
20	0.3	2	1	0.2118
20	0.3	1	2	0.1898

Meilleurs hyperparamètres : $k = 150$, $\theta = 0.6$, apply weight = 100, view weight = 1.

MRR = 0.0238, Accuracy = 0.7389, Final score = 0.2383.

Méthode à base de graphes

- Représenter l'ensemble des sessions sous forme de graphes orientés
- Les noeuds sont les postes et les arêtes représentent la probabilité qu'un individu regarde ou postule au prochain noeud
- Cela permet d'obtenir une structure de données efficaces pour obtenir tous les postes voisins à un poste et cela selon les données des sessions



Méthode à base de graphes

- Fonction de score pour un poste:

$$(1) \quad S(n)+ = \alpha \cdot w(j, n) \cdot \frac{e + 1}{|job_ids|}$$

$$(2) \quad S(n)+ = (1 - \alpha) \cdot sim(j, n) \cdot \frac{e + 1}{|job_ids|}$$

Pour chaque voisin d'un poste observé lors d'une session, nous allons augmenter son score à partir des deux termes ci dessus.

$w(j, n)$ correspond à la probabilité de transition selon l'action réalisée lors de la session et ce score est pondérée par un facteur de distance dans la session.

Méthode à base de graphes

alpha	hit rate	mrr
0	17.4	0.0770
0.2	17.5	0.0778
1	12.6	0.0521

Résultat de notre algorithme à base de graphe.

alpha = 0 correspond à n'utiliser que la similarité lors du scoring

alpha = 1 correspond à n'utiliser que la probabilité de transition

CF avec embeddings

Réutilisation de la décomposition par SVD de la matrice d'interaction R . On obtient U la représentation des utilisateurs et V la représentations des postes.

$$\mathbf{R}_{\text{svd}} = \mathbf{U} \text{diag}(\mathbf{s}) \mathbf{V}^T$$

CF avec embeddings

$$J = [V_k, E]$$
$$E \in \mathbb{R}^{n \times d}$$
$$J \in \mathbb{R}^{n \times (k+d)}$$

Augmentation de notre représentation des postes (V) grâce à notre matrice d'embeddings précédemment décrite. Afin de garder uniquement les valeurs importantes, notre matrice d'embeddings est aussi réduite par une décomposition SVD

CF avec embeddings

	MRR	Action Accuracy	Hit Rate
CF + SVD + Embeddings	0.0420	77.59%	10.0%
CF + SVD	0.0238	73.89%	N/A

Résultats

Méthode	MRR	Hit Rate	Action Accuracy
Baseline CF	0.0218	NA	62.49%
CF + SVD	0.0238	NA	73.89%
Graphe	0.0778	17.5%	72.36%
CF + SVD + Emb	0.0420	10.0%	77.59%

Tableau récapitulatif de nos résultats. La méthode par graphe montre qu'une méthode relativement simple sans apprentissage peut obtenir de bien meilleurs résultats que la baseline

Conclusion

- Contributions
 - Proposition de plusieurs méthodes pour la recommandation de postes selon les interactions de l'utilisateur.
 - Proposition d'une méthode par graphe nécessitant aucun entraînement, très rapide et facilement étendable à de nouvelles sessions et postes proposant des résultats convaincants.
 - Classés 6ème avec 28.99% avec la méthode des graphes
- Améliorations
 - Etendre la recherche de postes en utilisant les voisins nièmes plutôt que les premiers voisins uniquement
 - Amélioration de la fonction de score par Graph Neural Network, ou avec des heuristiques plus travaillées
 - Utiliser à la fois les transitions "view" et "apply" plutôt qu'uniquement celle observé lors de la session pour la recommandation